

Desafio bioinformático

AKCLab

Candidato: Dr. Wasim Aluísio Prates-Syed
wasim.syed@usp.br

Data: 5/8/26

Questão teórica - Resposta

Para confirmar a integração do cassette doador ao genoma via CRISPR/Cas9 e pelo mecanismo de reparo direto por homologia (HDR, **Figura 1A**) (**Passos-Silva et al., 2010**), é necessário primeiro selecionar as colônias por meio do tratamento com um marcador, no caso um marcador de resistência para puromicina, (**Figura 1B**) e também correr a reação de PCR com os mix de diferentes pares de primers aqui desenhados e depois correr um gel de agarose (**Figura 1C**). É importante utilizar como controles 1) uma amostra wild-type e 2) uma amostra com o cassette doador, além de comparar com 3) as amostras pós-transfecção. A partir do resultado do gel de agarose, finalmente deve-se sequenciar os amplicons, para verificar a integridade da sequência do inserto, e selecionar a colônia com melhor resultado (**Figura 1D**).

Desenho dos pares de primers de confirmação

Como os primers donor e gRNA já foram preditos para confirmar a integração por homologia, é necessário confirmar a integração do CDS do gene alvo e do gene a ser integrado, no caso o PuroR (**Figura 1A**). Para isso, o primer forward do gene alvo deve hibridizar dentro da região 5'-CDS (*confKO_AG01_intraAG01_PF*), e no caso do gene de interesse, o primer forward (*confKO_AG01_intraPURO_PF*) deve hibridizar também na região 5'-CDS, e não na sequência correspondente ao gene LmxM-33, já presente no genoma, evitando overlap off-target. Já o primer reverse (*confKO_AG01_3utrAG01_PR*) deve hibridizar com a região externa 3' flanqueando o braço doador (homology arm, HA) e não com a região 3' interna do braço doador, uma vez que o primer poderia hibridizar com a própria sequência do gRNA das moléculas que sobraram e não se integraram ao genoma.




Figura 1. Desenho de primers e de experimento de confirmação por PCR. (A) Esquema para o desenho de primers para construção de inserto por reparo homólogo direto, utilizando como exemplo a substituição do gene Ago1 pelo cassete com PuroR. O desenho dos primers deve considerar os braços de homologia (HA), o tamanho final do amplicon, e a âncora flanqueando o braço de homologia, além de parâmetros físico-químicos e moleculares, como estruturas secundárias e %GC. (B) Selecionar colônias por tratamento com o marcador de resistência, como a Puromicina, para confirmar a inserção do gene. (C) Resultado esperado em uma eletroforese em gel de agarose do produto da reação de PCR com diferentes combinações de primers. (D) Os amplicons são sequenciados para confirmar a integridade do inserto. Esquema criado no Biorender.

Embora os primers estejam contidos na região CDS, compreender todas as regiões citadas acima pode gerar amplicons imensos, sendo Ago1 (~2700 bp) e o cassete doador (~1800 bp), além das regiões HA. De acordo com a literatura, as espécies do gênero *Leishmania* requerem regiões HA com mais de 300 nt para integração do DNA doador (DEAN et al., 2015), o que corresponde visualmente ao encontrado na figura do enunciado.

Devido às limitações associadas com amplicons grandes, como tempo longo de corrida do PCR, nitidez reduzida no gel de agarose e integridade reduzida do template, é possível a posição inicial dos primers forward no CDS para reduzir para ~500 a ~1000 pb. Na figura fornecida no enunciado, é possível observar que os pares de primers intraAGO1_PF/3utrAGO1_PR compreendem ~650 nt, e os primers intraPURO_PF_3utrAGO1_PR, aproximadamente 1100 nt.

Resultado da eletroforese em gel de agarose

Especificamente no gel de agarose, considerando a inserção em ambos os alelos dos pares de cromossomos, deve-se utilizar dois pares de primers distintos (**Figura 1B**). Para o par de primers do gene-alvo (intraAGO1_PF e 3utrAGO1_PR), espera-se a amplificação de uma banda de ~650 bp na amostra WT, e a sua ausência na amostra pós-transfecção, o que confirma a perda de ambos os alelos do gene AGO1. Para o par de primers do gene de interesse (intraPURO_PF e 3utrAGO1_PR), espera-se a ausência de banda tanto na amostra WT, quanto na reação contendo apenas o cassete doador livre, devido ao flanqueamento do primer reverso na região genômica 3' UTR, externa ao cassete. Em contrapartida, na amostra pós-transfecção, espera-se a presença da banda correspondente ao amplicon de integração (~1100 bp), confirmando a inserção correta do marcador de resistência no locus-alvo.

Pipeline proposto para desenho de primers em batch

Para desenhar os primers de forma programática, é possível seguir o esquema da **Figura 1A**, na qual é necessário inserir como input: 1) as sequências do gene alvo + HA + âncora, e 2) as sequências do cassete doador. Esses dados de entrada podem ser inseridos em uma ferramenta como o pacote rprimer (PERSSON et al., 2022), com as propriedades definidas (tamanho dos primers, tamanho esperado do

amplicon, %GC, T_m e estruturas secundárias) com base nos protocolos padronizados do laboratório (DIEFFENBACH et al., 1993).

Além disso, é necessário identificar possíveis regiões off-target, prevenindo anelamentos inespecíficos decorrentes de eventuais quebras induzidas pelo gRNA ou micro-homologias em outras regiões do genoma (SAMPAIO et al., 2021). Para procurar essas sequências off-target de amplicons possíveis e de primers, o pacote rBLAST pode ser utilizado executando a função BLASTn contra as sequências genômicas das diferentes espécies do gênero *Leishmania* baixadas do TriTrypDB ou do NCBI (ASLETT et al., 2010; CAMACHO et al., 2009). Essas sequências genômicas podem ser utilizadas para criar um banco de dados local como referência para os alinhamentos, uma vez que a espécie exata não foi especificada no enunciado.

Em resumo, o pipeline deve seguir as seguintes etapas:

Parte de bioinformática:

1. Selecionar os genes de interesse e genes alvo
2. Para cada gene-alvo e gene de interesse, desenhar primers forward no intra-CDS, e primers reverse contendo 300 nt (braço de homologia) + 30 nt (flank externo) downstream ao final do CDS
3. Comparar sequências com o genoma referência, para descobrir off-targets
4. Definir parâmetros físico-químicos e moleculares para o desenho dos primers
5. Calcular tamanho dos amplicons pela distância entre o início dos primers forward e o final do primer reverse.

Parte experimental:

1. Cultivar células e tratar com puromicina
2. Selecionar melhores colônias
3. Sintetizar primers
4. Correr a PCR nas amostras e nos controles
5. Coletar produto das reações e aplicar no gel de agarose
6. Analisar gel e comparar as bandas
7. Confirmar integração precisa do inserto, por sequenciamento

Referências

1. **Dean S, Sunter J, Wheeler RJ, Hodgkinson I, Gluenz E, Gull K. (2015).** A toolkit enabling efficient, scalable and reproducible gene tagging in trypanosomatids. *Open Biol.* 5, 140197 (doi:10.1098/rsob.140197)
2. **Passos-Silva, D. G., et al. (2010).** "Overview of DNA repair in Trypanosomatids: More than just pathways." **Critical Reviews in Microbiology**, 36(3), 239-250. (Descreve a ausência de NHEJ em tripanosomatídeos).
3. **Dieffenbach, C. W., et al. (1993).** "General concepts for PCR primer design." **PCR Methods and Applications**, 3(3), S30-S37.
4. **Camacho, C., et al. (2009).** "BLAST+: architecture and applications." **BMC Bioinformatics**, 10, 421.
5. **Sampaio, G. L., et al. (2021).** "Microhomology-Mediated End Joining (MMEJ) in Trypanosomatids: Mechanisms and Exploitation for Genome Editing." **Frontiers in Cellular and Infection Microbiology**, 11, 638018.
6. **Persson S, Larsson C, Simonsson M, Ellström P (2022).** "rprimer: an R/bioconductor package for design of degenerate oligos for sequence variable viruses." *BMC Bioinformatics*, 23(239). <https://bmcbioinformatics.biomedcentral.com/articles/10.1186/s12859-022-04781-0>.

Desafio prático

Devido a limitações computacionais locais na execução do pipeline (mesmo em ambiente isolado via Conda/Docker e com subamostragem dos arquivos FASTQ) e à ausência de dados de exemplo no repositório original, optou-se pela utilização de um conjunto de dados público de ncRNAs de *Leishmania* baixado do artigo intitulado "*Comparative and systems analyses of Leishmania spp. non-coding RNAs through developmental stages*" (PLOS Neglected Tropical Diseases, DOI: 10.1371/journal.pntd.0013108), permitindo o desenvolvimento e a validação do script de visualização dos resultados.

O Markdown/PDF enviado por email contém os scripts para preparar os dados utilizados como input no pipeline TriTryp-ncRNA, bem como a execução do mesmo adaptado para o ambiente R/Markdown. Além disso, contém também os códigos para limpeza do dataset do artigo citado acima e para a visualização simples desses dados.

Os gráficos, produzidos no ggplot2 e com a paleta do grupo Nature, também podem ser visualizados abaixo (**Figura 2**).




Figura 2. Análise exploratória da distribuição genômica e perfil de tamanho de ncRNAs em *Leishmania braziliensis*. (A) Distribuição dos grupos funcionais de ncRNAs ao longo da localização cromossômica. (B) Mediana do tamanho (nt) por classe de ncRNA, agrupada e colorida por categoria funcional. As barras indicam a mediana e as linhas de erro representam o intervalo de confiança de 95%. (C) Distribuição do tamanho por classe de ncRNA, visualizada por boxplots e raincloud plots, facetada por grupo funcional.